

Vaihe 3: Piirteiden valinta ja perustelut

Ensemble-menetelmät trading-setupien laadun ennustamisessa

1. Vaiheen tavoite ja dokumentin tarkoitus

Vaiheen 3 tavoitteena on rakentaa moduuli `src/features.py`, joka lisää jokaiselle Vaiheessa 2 tunnistetulle setupille joukon ennustepiirteitä. Nämä piirteet muodostavat ML-mallien syöteavaruuden Vaiheessa 4. Tuotos on tiedosto `data/processed/setups_with_features.parquet`.

Tämä dokumentti perustelee, miksi tietyt piirteet otetaan mukaan ja miksi toiset jätetään pois. Dokumentointi tehdään ennen toteutusta, koska piirteiden valinta on tieteellisesti merkittävin yksittäinen päätös tässä vaiheessa: liian moni piirre johtaa ylioppimiseen, liian harva taas estää mallia oppimasta hyödyllisiä riippuvuuksia. Käymällä jokainen ehdokas läpi etukäteen ja dokumentoimalla päätökset varmistetaan tieteellinen rehellisyys ja toistettavuus.

2. Lähtökohta ja valintaperiaatteet

Vaiheessa 2 löydetty keskeinen tulos toimii lähtökohtana: voitto-prosentti laskee monotonisesti `setup_index_in_day:n` myötä (ensimmäinen päivän setup 11,0 %, kymmenes 0,0 %). Tämä osoittaa, että setupin ominaisuuksilla on todellista ennustearvoa — ML:n tehtävä on löytää lisää tämänkaltaisia signaaleja.

Piirteiden valinnassa noudatetaan kolmea periaatetta:

- **Vähemmän on enemmän:** 8 281 setupia on hyvä otos, mutta ei valtava. Jos piirteitä on 30+, ensemble-mallit löytävät helposti vääriä kuvioita (overfit). Tavoitellaan noin 12–14 perusteltua piirrettä.
- **Korreloituneet piirteet karsitaan:** esimerkiksi ATR ja boxin koko korreloivat voimakkaasti, joten molempia ei oteta sellaisenaan.
- **Jokaisella piirteellä on perustelu:** ei ad hoc -ideoita ilman teoreettista tai empiiristä lähtökohtaa. Tämä mahdollistaa myös tulosten jälkikäteisen tulkinnan.

3. Look-ahead-bias ja sen välttäminen

Look-ahead bias tarkoittaa sitä, että malli käyttää piirteenään tietoa, jota sillä ei oikeasti olisi ollut sillä hetkellä, kun kauppa pitäisi tehdä. Tämä on aikasarja-koneoppimisen yleisin ja salakavalin virhe — se tuottaa upeat tulokset koulutusdatalla mutta kaatuu täysin oikeassa kaupankäynnissä.

Konkreettinen esimerkki: setup syntyy 15min-kynttilän sulkeutuessa hetkellä 14:00 UTC. Jos piirteeksi laskettaisiin "päivän RSI" käyttäen koko päivän dataa (00:00–23:59), olisi käytetty klo 14:00:n kaupassa tietoa, joka oli saatavilla vasta klo 23:59. Malli oppisi, että "korkea päivän RSI ennustaa voittoa" — koska se tietää loppupäivän liikkeen — mutta tämä ei toimi oikeassa kaupankäynnissä.

Toteutusperiaate: kaikki piirteet lasketaan käyttäen vain `entry_time:tä` edeltäviä päättäneitä kynttilöitä. Kun piirre lasketaan korkeammalta aikakehykseltä (1h, 4h, 1d), käytetään sen aikakehyksen viimeistä päättynyttä kynttilää `entry_time:n` hetkellä — ei sitä, joka on parhaillaan käynnissä. Tämä on sama disiplinaari kuin Vaiheessa 2 toteutetussa setup-detektorissa.

4. Piirreryhmät ja yksittäisten piirteiden perustelut

Piirteet on jaoteltu viiteen ryhmään loogisen kokonaisuuden mukaan. Jokainen taulukko sisältää sarakkeet: piirre, suositus ja perustelu. Suositukset on värikoodattu: MUST (vihreä), HYVÄ (vaalea vihreä), HARKINNAN (keltainen), POISTA (oranssi).

4.1 Ryhmä A: Setup-piirteet

Setupin omat geometriset ja ajalliset ominaisuudet. Useimmat näistä ovat jo setups.parquet-tiedostossa tai johdettavissa siitä yksinkertaisilla laskuilla.

Piirre	Suositus	Perustelu
setup_index_in_day	MUST	Vaiheen 2 keskeinen löytö. Voitto-% laskee monotonisesti (11,0 % → 0,0 %). Vahvin yksittäinen signaali, jonka tiedämme datasta.
direction (long/short)	MUST	Helposti laskettavissa. Mahdollistaa mallin oppia eri tavalla nouseville ja laskeville setupeille — esim. karhumarkkinassa shortit voivat toimia paremmin.
risk_reward_ratio	MUST	Kuvaa setupin geometriaa: kuinka suuri palkkio suhteessa riskiin. Suuri R/R ei automaattisesti tarkoita parempaa, mutta on perustietoa setupin laadusta.
box_size_pct	MUST	Boxin koko prosentteina sisäänmenohinnasta. Pienet boxit = ahtaat liikkeet (ehkä range), isot = volatiilit päivät. Tämä on volatilitiiproxy ilman erillistä ATR-laskua.
entry_position_in_box	HYVÄ	Sisäänmenohinnan etäisyys boxin keskiviivasta, normalisoitu boxin koolla (-1..1). Kuvaa kuinka kaukana keskiviivasta käännekynttilä syntyi.
hour_of_day (UTC)	HYVÄ	Kryptomarkkinassa on selkeät aktiviteettisyklit: Aasian, Euroopan ja US:n avaukset. Esim. US-avaus klo 13:30 UTC tuo usein vahvempia liikkeitä. Koodataan sykliseksi (sin/cos).
day_of_week	HARKINNAN	Voi olla heikko signaali (viikonloppu vs. arki). Jätetään pois alkuvaiheessa — jos mallit jäävät heikoiksi, voidaan lisätä myöhemmin.

4.2 Ryhmä B: Boxin konteksti

Boxin määräytymisen taustalla oleva edellisen päivän kynttilä ja sen suhde laajempaan volatilitiettiin. Iso edellisen päivän liike tarkoittaa isoa boxia tänään, mikä muuttaa setupien dynamiikkaa.

Piirre	Suositus	Perustelu
prev_day_range_pct	HYVÄ	Edellisen päivän kynttilän koko (high-low) prosentteina. Iso edellinen päivä ennakoi isoa boxia tänään — mutta myös potentiaalisesti volatiilimpaa hintaliikettä, jolloin SL-osumat voivat olla yleisempiä.

Piirre	Suositus	Perustelu
box_size_vs_atr14d	HYVÄ	Boxin koko jaettuna 14 päivän ATR:llä. Normalisoi boxin koon yleiseen volatiliteettiin: "onko tämä boxi keskimääräinen vai poikkeuksellinen?" Tämä lisää informaatiota box_size_pct:n päälle.
prev_day_color (green/red)	POISTA	Korreloi voimakkaasti 1d-trendin kanssa, joka on jo mukana. Jätetään pois redundanssin välttämiseksi.

4.3 Ryhmä C: Trendi multi-timeframe

Korkeamman aikakehyksen trendi on käytännön kaupankäynnissä yleisesti tunnustettu konteksti. Trendin suuntainen setup on perinteisesti pidetty todennäköisempänä voittajana. Otetaan vain yksi piirre tästä ryhmästä, koska 1h, 4h ja 1d -trendit korreloivat vahvasti keskenään.

Piirre	Suositus	Perustelu
trend_4h (EMA50 vs. EMA200)	MUST	Mitataan etumerkillisenä prosenttieronä: $(EMA50 - EMA200) / EMA200 \times 100$. Positiivinen = nouseva trendi, negatiivinen = laskeva. 4h on kompromissi nopean reagoinnin (1h, kohinaa) ja hitaan trendin (1d, viiveinen) välillä.
trend_1h (EMA50 vs. EMA200)	POISTA	Korreloi 4h-trendin kanssa, mutta on kohinaisempi. Jos halutaan vain yksi trendi-piirre, 4h on parempi.
trend_1d	POISTA	1d-data on niukkaa (~860 päivää koko aikavälillä). EMA200 päivätasolla tarvitsisi pitkän historian, ja arvo on viiveinen. Riski overfittiin korkea, lisäarvo pieni 4h:n päälle.

4.4 Ryhmä D: Volatiliteetti ja momentum

Sisäänmenohetken markkinatilanne: kuinka volatiliia on juuri nyt, onko hinta yliostettu/-myyty, miten volyyymi käyttäytyy. Nämä ovat klassisia teknisen analyysin indikaattoreita, joiden ennustearvosta on sekä puoltavia että vastustavia näkemyksiä — ML:n tehtävä on selvittää, onko niillä todellista signaalia tässä asetelmassa.

Piirre	Suositus	Perustelu
atr14_15m_pct	MUST	ATR(14) 15min-aikakehyksellä, prosentteina sisäänmenohinnasta. Kuvaa nykyhetken volatiliteettia. Korkea ATR = liike voi nopeasti osua sekä TP:hen että SL:ään.
rsi14_15m	HYVÄ	RSI(14) 15min-aikakehyksellä sisäänmenohetkellä. Klassinen overbought (>70) / oversold (<30) -indikaattori. Box Methodissa setupit syntyvät käännoöksissä, joten RSI:n ääriarvot voivat olla informatiivisia.
volume_ratio (entry vs. päivän ka.)	HYVÄ	Sisäänmenokynttilän volyyymi suhteessa päivän siihen mennessä toteutuneeseen keskimääräiseen volyyymiin.

Piirre	Suositus	Perustelu
		Korkea volyymi käännöskohdassa on perinteisesti pidetty vahvuusmerkkinä.
rsi14_1h	HARKINNAN	Voi olla redundantti 15min RSI:n kanssa. Jätetään pois alkuvaiheessa — jos 15min RSI osoittautuu hyödylliseksi, voidaan myöhemmin testata, tuoko 1h lisäarvoa.

4.5 Ryhmä E: Päivän sisäinen rakenne

Setupin syntyhetkeen liittyvät rakenteelliset piirteet, jotka eivät mahdu muihin ryhmiin: käännekynttilän voimakkuus suhteessa muuhun päivään.

Piirre	Suositus	Perustelu
reversal_candle_size_vs_avg	HYVÄ	Käännekynttilän koko (high-low) jaettuna päivän siihenastisten kynttilöiden keskimääräisellä koolla. Iso käännekynttilä = voimakas hylkäys = perinteisesti vahvempi signaali.
minutes_from_day_start	POISTA	Käytännössä sama tieto kuin hour_of_day. Redundantti.
minutes_since_prev_setup	HARKINNAN	Mielenkiintoinen idea: peräkkäin lyhyellä välillä tulevat setupit voivat olla heikompia. Tämä on kuitenkin osittain päällekkäinen setup_index_in_day:n kanssa. Jätetään pois alkuvaiheessa.

5. Lopullinen piirrejoukko

Edellisten taulukoiden perusteella lopulliseen piirrejoukkoon valitaan seuraavat 12 piirrettä:

Ryhmä	Piirteet
A: Setup-piirteet (6)	setup_index_in_day, direction, risk_reward_ratio, box_size_pct, entry_position_in_box, hour_of_day
B: Boxin konteksti (2)	prev_day_range_pct, box_size_vs_atr14d
C: Trendi (1)	trend_4h
D: Volatiliteetti ja momentum (3)	atr14_15m_pct, rsi14_15m, volume_ratio
E: Päivän sisäinen rakenne (1)	reversal_candle_size_vs_avg

Yhteensä 13 piirrettä (jos hour_of_day lasketaan kaksiosaisena sin/cos-koodauksena, määrä on 14). Tämä on perusteltu kompromissi datamäärän ja mallin oppimiskyvyn välillä.

6. Jatkokehitysmahdollisuudet

Mikäli Vaiheen 4 mallit eivät saavuta riittävää suorituskkyä, seuraavat piirteet voidaan lisätä kokeellisesti, yksi kerrallaan, ja niiden vaikutus testataan ristiinvalidoinnilla:

- `day_of_week` — viikonpäivävaihtelu, helppo lisätä
- `rsi14_1h` — pidemmän aikakehyksen RSI lisäkontekstina
- `minutes_since_prev_setup` — peräkkäisten setupien tihentymä
- `trend_1h` — nopeampi trendi-indikaattori lisäpiirteenä

Tärkeää on, että näitä ei lisätä "vain varmuuden vuoksi". Lisäys perustellaan empiirisesti: jos baseline-mallit jäävät heikoiksi tietyssä alaryhmässä (esim. ranging-markkina), kohdennetaan piirteiden lisäys siihen ongelmaan.

7. Toteutusperiaatteet

Moduuli `src/features.py` rakennetaan inkrementaalisesti yhden ryhmän kerrallaan. Jokaisen ryhmän jälkeen tehdään sanity-tarkistus ennen seuraavaan siirtymistä:

- **NaN-tarkistus:** kuinka monessa setupissa piirre on määrittelemätön? Mikä on syy (esim. liian vähän historiaa indikaattorin laskemiseen alkupäivillä)?
- **Jakauma:** histogrammi tai tilastolliset tunnusluvut (min, max, mediaani, keskihajonta). Onko piirre järkevän näköinen?
- **Yksittäismuuttuja-analyysi:** voitto-% piirteiden kvintiileittäin. Onko piirteellä yksinään ennustearvoa?
- **Korrelaatio aiempiin piirteisiin:** kuinka voimakkaasti uusi piirre korreloi jo lisättyihin? Jos $> 0,9$, harkitaan toisen poistamista.

Tämä disipliini hidastaa toteutusta hieman, mutta varmistaa että jokaisen piirteiden rooli on ymmärretty ennen mallien koulutusta. Vaiheen 4 tulosten tulkinta on huomattavasti helpompaa, kun piirreavaruus tunnetaan hyvin.

8. Yhteenveto

Vaiheen 3 piirresuunnitelma perustuu kolmeen periaatteeseen: vähemmän on enemmän, korreloituneet piirteet karsitaan, ja jokaisella piirteellä on dokumentoitu perustelu. Lopullinen joukko sisältää 13 piirrettä viidestä ryhmästä, ja se kattaa setupin geometrian, boxin kontekstin, korkeamman aikakehyksen trendin, sisäänmenohetken volatiliiteetin ja momentumin sekä käännekynttilän rakenteelliset ominaisuudet.

Look-ahead-bias estetään periaatteella "laske aina vain `entry_time`:tä edeltävistä päättyneistä kynttilöistä". Tämä on sama disipliini, jota Vaiheen 2 setup-detektorissa noudatettiin.

Seuraava askel on rakentaa moduuli `src/features.py` inkrementaalisesti ryhmä kerrallaan, ja tallentaa lopputulos tiedostoon `data/processed/setups_with_features.parquet`. Tämä antaa lähtökohdat Vaiheen 4 ensemble-mallien koulutukselle.