

Ryhmä B: Boxin konteksti -piirteiden löydöt

Ensemble-menetelmät trading-setupien laadun ennustamisessa

1. Dokumentin tarkoitus

Ryhmä B sisältää boxin kontekstipiirteet, jotka liittävät yksittäisen setupin laajempaan markkinatilanteeseen. Konkreettisesti ryhmässä on kaksi piirrettä: edellisen päivän liikkeen koko ja boxin koko suhteessa 14 päivän keskimääräiseen volatiliiteettiin (ATR).

Tämä dokumentti tiivistää Ryhmä B:n toteutuksen ja sen tuottamat löydöt. Ryhmä B:n analyysi paljasti yhden erittäin vahvan ennustepiirteen ja tunnisti päällekkäisyyden Ryhmä A:n piirteen kanssa, mikä johti yhden Ryhmä A:n piirteen poistamiseen.

2. Toteutetut piirteet

Piirre	Lähde	Laskukaava / huomio
prev_day_range_pct	Päivätason data	$(\text{prev_day_high} - \text{prev_day_low}) / \text{prev_day_close} \times 100$
box_size_vs_atr14d	Päivätason data	$\text{box_size} / \text{ATR}(14d)$, missä ATR on True Range:n liukuva keskiarvo 14 päivältä

2.1 ATR (Average True Range) – kertaus

ATR on klassinen volatiliiteettimitta. Kunakin päivänä True Range (TR) on suurin näistä kolmesta:

- $\text{high} - \text{low}$
- $|\text{high} - \text{previous_close}|$
- $|\text{low} - \text{previous_close}|$

Toinen ja kolmas kaava huomioivat "gapit" eli päivien väliset hyppyävät avaukset. ATR(14) on TR:n liukuva keskiarvo viimeisten 14 päivän yli.

2.2 Look-ahead-bias

Kummassakin piirteessä käytetään vain setupin date-päivän päivätason dataa, joka on päättynyt ennen setupin entry_time:ä. Tämä on luonnollinen raja, koska boxi muodostuu joka tapauksessa edellisen päivän perusteella. Toteutus on tiedostossa src/features.py funktiossa add_group_b_features().

2.3 Sanity-tarkistus

Piirteiden jakaumat ovat järkeviä:

- prev_day_range_pct: keskiarvo 6,6 %, mediaani 5,8 %, klassinen oikealle vino jakauma — 0 NaN-arvoa

- `box_size_vs_atr14d`: keskiarvo 0,95, mediaani 0,87 — 99 NaN-arvoa (`ATR(14)`:n vaatima 14 päivän lämmittelyaika alkupäivinä)

Mediaani $0,87 < 1,0$ vahvistaa geometrian järkevyyden: `ATR` huomioi gappeja, kun taas `boxin` koko on pelkkä yhden päivän high-low, joten `ATR` on luonnollisesti hieman suurempi keskimäärin.

3. Löytö 4: Edellisen päivän koko on heikko ennustepiirre

Hypoteesi oli, että iso edellisen päivän liike enteilee volatiilimpaa tänään, mikä muuttaa setupien dynamiikkaa. Kvintiilianalyysi paljasti, että ennustearvo on olemassa mutta heikko ja epämonotoninen.

3.1 Voitto-% `prev_day_range_pct` -kvintiileittäin

Kvintiili	Range keskiarvo (%)	n	Voitto-%
Q1 (pienin)	3,01	1 317	6,83 %
Q2	4,57	1 310	6,95 %
Q3	5,96	1 314	5,71 %
Q4	7,72	1 313	7,62 %
Q5 (suurin)	12,47	1 312	8,16 %

Voitto-% vaihtelee välillä 5,7–8,2 %, eli alle 2,5 prosenttiyksikön ero äärikvintiilien välillä. Suhde on lievästi nouseva (Q1 → Q5), mutta ei monotoninen: Q3:ssa on alin voitto-%, mikä viittaa kohinaan. Vertailuksi, Ryhmä A:n vahvat löydöt (`R/R`, `entry_outside_box`) tuottivat 6–17 prosenttiyksikön eroja.

3.2 Päätös: piirre säilytetään

Vaikka `prev_day_range_pct` on yksinään heikko ennustepiirre, se säilytetään ML-mallien syöteavaruudessa. Ensemble-mallit voivat löytää siitä arvoa vuorovaikutuksessa muiden piirteiden kanssa — esim. "iso edellinen päivä + `boxi` rikki + matala `R/R`" voi olla erilaista signaalia kuin näiden osatekijöiden summa. Yksinäinen heikkous ei tarkoita kombinaatioiden heikkoutta.

4. Löytö 5: `box_size_vs_atr14d` on erittäin vahva ennustepiirre

Tämä on Ryhmä B:n pääsignaali ja kolmas erittäin vahva monotoninen ennustepiirre koko projektissa (`setup_index_in_day` ja `risk_reward_ratio` ovat aiempia).

4.1 Voitto-% `box_size_vs_atr14d` -kvintiileittäin

Kvintiili	Suhde keskiarvo	n	Voitto-%
Q1 (pienin)	0,46	1 317	12,53 %

Kvintiili	Suhde keskiarvo	n	Voitto-%
Q2	0,67	1 312	8,69 %
Q3	0,86	1 311	6,41 %
Q4	1,08	1 313	4,95 %
Q5 (suurin)	1,64	1 313	2,67 %

Voitto-% laskee monotonisesti 12,53 %:sta 2,67 %:iin. Q1:n voitto-% ylittää kannattavuusrajan (~11,1 %), eli pienet boxit suhteessa ATR:ään muodostavat itsessään lähes kannattavan alaryhmän — vahvempi kuin pelkkä "ensimmäinen setup per päivä" (Vaiheen 2 löytö, 11,0 %).

4.2 Tulkinta: miksi pienet boxit voittavat

Pieni boxi suhteessa ATR:ään tarkoittaa: "tänään hinta on ollut keskimääräistä rauhallisempi". Setupit muodostuvat siis hiljaisten päivien aikana. Hiljaiset päivät → tiukemmat boxit → kapeammat liikkeet → TP- ja SL-tasot lähempänä toisiaan → TP on suhteellisen helppo saavuttaa.

Tämä on geometrisesti yhteydessä Ryhmä A:n R/R-paradoksiin (Löytö 2): hiljaisilla päivillä myös R/R on luonnollisesti matalampi (lyhyemmät matkat). Molemmat löydöt viittaavat samaan rakenteelliseen ilmiöön — Box Method toimii parhaiten rauhallisessa markkinassa.

5. Korrelaatioanalyysi ja box_size_pct:n poisto

Ryhmä B:n vahvuus motivoi tarkistamaan, onko piirre päällekkäinen Ryhmä A:n piirteiden kanssa. Erityisesti box_size_pct (Ryhmä A) ja box_size_vs_atr14d (Ryhmä B) molemmat mittaavat boxin kokoa eri jakajalla:

- $\text{box_size_pct} = \text{boxin koko} / \text{entry_price}$
- $\text{box_size_vs_atr14d} = \text{boxin koko} / \text{ATR}(14)$

5.1 Korrelaatiomatriisi

	box_size_vs_atr14d	risk_reward_ratio	box_size_pct
box_size_vs_atr14d	1,000	0,478	0,811
risk_reward_ratio	0,478	1,000	0,470
box_size_pct	0,811	0,470	1,000

Korrelaatio $\text{box_size_pct} \leftrightarrow \text{box_size_vs_atr14d} = 0,811$ — erittäin korkea. Molemmissa boxin koko on osoittajassa, ja jakaja muuttuu hitaasti. Korrelaatio risk_reward_ratio:n kanssa on selvästi matalampi (0,48), joten R/R sisältää merkittävää omaa informaatiota molempien kanssa.

5.2 Vertaileva kvintiilianalyysi

Ennen poistopäätöstä testattiin `box_size_pct`:n yksinäinen ennustearvo:

Kvintiili	<code>box_size_pct</code> voitto-%	<code>box_size_vs_atr14d</code> voitto-%	<code>box_size_pct</code> keskiarvo	Vertailu
Q1	12,94 %	12,53 %	2,50 %	≈
Q2	7,31 %	8,69 %	3,87 %	↓
Q3	7,46 %	6,41 %	5,01 %	↑ (kuoppa)
Q4	5,10 %	4,95 %	6,60 %	≈
Q5	2,44 %	2,67 %	10,88 %	≈

Molemmat piirteet ovat vahvoja, mutta:

- **`box_size_vs_atr14d` on täysin monotoninen:** $12,53 \rightarrow 8,69 \rightarrow 6,41 \rightarrow 4,95 \rightarrow 2,67$. Ei yhtään kuoppaa.
- **`box_size_pct` ei ole täysin monotoninen:** Q2 (7,31 %) on matalampi kuin Q3 (7,46 %). Pieni anomalia, mutta merkki kohinaisemmasta signaalista.

5.3 Päätös: `box_size_pct` poistetaan Ryhmä A:sta

Perustelut päätökselle:

- Korrelaatio 0,811 — ML-mallit (erityisesti lineaariset) eivät hyödy päällekkäisestä piirteestä, ja puumallit voivat oppia oudosti
- `box_size_vs_atr14d` on yhtä vahva tai vahvempi (Q1: 12,53 vs. 12,94 % — käytännössä sama)
- `box_size_vs_atr14d` on täysin monotoninen, `box_size_pct` ei
- `box_size_vs_atr14d` on teoreettisesti perustellumpi — huomioi 14 päivän markkinakontekstin, kun `box_size_pct` mittaa vain suhteellista kokoa nykyhetkellä

Päätös: `box_size_pct` poistetaan `add_group_a_features`-funktioista. Päätös on dokumentoitu lähdekoodissa kommenttina, jotta päätöksen logiikka säilyy projektin historiassa. Tämä on hyvä esimerkki tieteellisestä piirrekarsinnasta: kaksi vahvaa piirrettä, päällekkäisyys havaittu kvantitatiivisesti, valittiin parempi.

6. Ryhmä B:n yhteenveto

Piirre	Havainto	Vahvuus
<code>prev_day_range_pct</code>	Lievästi nouseva, epämonotoninen (5,7–8,2 %). Säilytetään ML-mallien vuorovaikutuksia varten.	Heikko
<code>box_size_vs_atr14d</code>	Erittäin vahva, täysin monotoninen lasku $12,53 \% \rightarrow 2,67 \%$. Q1 ylittää kannattavuusrajan yksinäänkin.	Erittäin vahva

6.1 Päivitetty piirrejoukko Ryhmien A ja B jälkeen

Ryhmä	Piirteet
A: Setup-piirteet (5)	setup_index_in_day, direction, risk_reward_ratio, entry_position_in_box + entry_outside_box (lippu), hour_sin + hour_cos
B: Boxin konteksti (2)	prev_day_range_pct, box_size_vs_atr14d
Poistettu	box_size_pct (Ryhmä A) — korrelaatio 0,811 box_size_vs_atr14d:n kanssa

Yhteensä 9 numeerista piirrettä (mukaan lukien hour_sin/hour_cos erikseen ja entry_outside_box -lippu).

6.2 Kumulatiiviset löydöt

Yhteenveto kaikista projektin merkittävistä löydöistä Vaiheen 2 ja Ryhmien A–B jälkeen:

Löytö	Havainto	Vahvuus
1. setup_index_in_day	Monotoninen lasku 11 % → 0 %	Vahva
2. risk_reward_ratio	Käänteinen, 18 % → 1,4 %	Erittäin vahva, vasta-intuitiivinen
3. entry_outside_box	Boxi ehjä 9,8 %, rikki 3,1 %	Vahva
4. EV negatiivinen	Kaikissa R/R-kvintileissä	Metodologisesti tärkeä baseline
5. box_size_vs_atr14d	Monotoninen lasku 12,5 % → 2,7 %	Erittäin vahva

Kaksi löydöstä (R/R-paradoksi ja box_size_vs_atr14d) viittaavat samaan rakenteelliseen ilmiöön: Box Method toimii parhaiten rauhallisessa markkinassa, jossa boxit ovat pieniä ja R/R-suhde on alhainen. Tämä on koherentti teoria, joka selittää useita itsenäisiä havaintoja samalla mekanismilla — hyvä merkki tieteellisestä validiudesta.

6.3 Seuraava askel

Siirrytään Ryhmä C:hen (multi-timeframe trendi): trend_4h. Tämä on yksi piirre, joka tuo mukaan 4h-aikakehyksen EMA50 vs. EMA200 -suhteen. Tämän jälkeen Ryhmä D (volatiliteetti ja momentum: ATR, RSI, volume) ja Ryhmä E (käännekynttilän rakenne).