

Ryhmä D: Volatiliteetti ja momentum

Löydösdokumentti

1. Vaiheen tavoite

Ryhmä D:n tavoitteena on tuottaa Box Method -setupeille volatiliteettia ja momenttia kuvaavia piirteitä, jotka täydentävät aiempien ryhmien (A: setup-piirteet, B: boxin konteksti, C: multi-timeframe-trendi) tuottamaa piirreavaruutta.

Piirteet on suunniteltu testaamaan ja tarkentamaan aiempien ryhmien tulosten pohjalta muotoutunutta työhypoteesia, jonka mukaan Box Method on mean reversion -tyyppinen strategia, joka toimii parhaiten rauhallisessa markkinassa. Ryhmä D laajentaa tarkastelua kahteen uuteen ulottuvuuteen: lyhyen aikavälin volatiliteettiin (ATR) ja momenttiin (RSI), sekä yhteen tukevaan piirteeseen (volyymisuhde).

2. Suunnitellut piirteet ja parametrivalinnat

Vaiheen alussa suunniteltiin yhteensä 7 piirrettä kolmessa alaryhmässä: ATR (4 piirrettä), RSI (2 piirrettä) ja volyymi (1 piirre). Korkean korrelaation perusteella karsittiin myöhemmin 3 piirrettä (ks. luku 5), jolloin lopullinen piirremäärä on 4.

2.1 ATR-piirteet

ATR (Average True Range) mittaa volatiliteettia. Aikakehyksiksi valittiin 15 minuuttia (pääaikakehys) ja 1 tunti (laajempi konteksti). Korkeamman aikakehyksen (4h) lisääminen ei olisi tuottanut merkittävää lisäarvoa, koska 4h-ATR muuttuu hitaasti samaan aikaan kun setupeja syntyy.

Esitysmuodoksi valittiin sekä absoluuttinen (% hinnasta) että suhteellinen (jaettuna päiväkehysten ATR:llä) näkökulma, koska ne mittaavat eri asioita. Absoluuttinen kertoo kuinka paljon hinta liikkuu rahallisesti, suhteellinen kertoo onko sisäänmenohetki rauhallisempi vai myrskyisämpi kuin päivän keskimääräinen volatiliteetti.

2.2 RSI-piirteet

RSI (Relative Strength Index) on klassinen momentum- ja mean reversion -indikaattori asteikolla 0–100. Aikakehyksiksi valittiin 15 minuuttia ja 1 tunti, periodiksi vakiintunut RSI(14). Esitysmuotona käytetään raakaa RSI-arvoa (0–100); puumallit pystyvät tarvittaessa löytämään ääripäät itse ilman erillisiä lippumuuttujia.

Laskentamenetelmänä käytetään Wilderin alkuperäistä eksponentiaalista tasoitusta ($\alpha = 1/N$, `adjust=False`), joka on TradingView-yhteensopiva. Tämä on linjassa Ryhmä C:n EMA-laskennan kanssa.

2.3 Volyymipiirre

Volyymipiirteenä käytetään suhdetta sisäänmenohetken volyymin ja edellisen 20 kynttilän (eli viimeisen 5 tunnin) keskiarvon välillä. Tämä antaa stabiilin määritelmän, joka ei kärsi päivän alun epästabiilisuongelmasta. Aikakehyksenä vain 15 minuuttia: useamman aikakehyksen volyymit ovat oleellisesti aikaikkunan kestoja toisistaan eivätkä tuo merkittävää lisätietoa.

3. Tekninen toteutus

Toteutus löytyy moduulista src/features.py, funktiosta add_group_d_features(setups_df, df_15m, df_1h, df_1d). Funktion rakenne:

- Lasketaan ATR, RSI ja volyymin liukuva keskiarvo raakakynttilätaulukoille symbolikohtaisesti, jotta indikaattorit eivät vuoda symbolista toiseen.
- Yhdistetään lasketut indikaattorit setupeihin pd.merge_asof-tekniikalla, käyttäen direction='backward' ja kynttilöiden close_time-saraketta look-ahead-suojauksena.
- Päiväkehysten ATR poimitaan edellisen valmiin päiväkynttilän arvosta; sisäänmenohetkellä saman päivän kynttilä ei vielä ole valmis.
- Lopuksi johdetaan normalisoidut piirteet (esim. atr_1h_pct = atr_1h / entry_price) ja siivotaan välilaskennan sarakkeet.

3.1 Look-ahead-suojaus

Look-ahead-vuoto on yksi vakavimmista virheistä trading-koneoppimisessa. Funktiossa jokainen indikaattori liitetään setupeihin pd.merge_asof-tekniikalla, jossa merge tehdään setupin entry_time:n ja kynttilän close_time:n välillä. Tämä takaa, että käytössä on aina ja vain viimeisin täysin valmis kynttilä ennen entry_time:ä. Käytäntö on yhdenmukainen Ryhmä C:n kanssa.

3.2 Defensiivinen siivous

Toteutuksen aikana havaittiin, että Ryhmä C:n merge_asof oli jättänyt välitallennukseen tarpeettoman close_time-sarakkeen. Tämä aiheutti virheen Ryhmä D:n merge-operaatioissa (sarakkeet nimettiin uudelleen close_time_x ja close_time_y). Korjauksena Ryhmä D:n funktion alkuun lisättiin defensiivinen sarakkeiden siivous, joka pudottaa kaikki close_time-jäänteet ennen merge-operaatioita. Korjaus siivoaa samalla Ryhmä C:n jättämän jäänteen lopullisesta välitallennuksesta.

4. Kvintiilianalyysi

Kvintiilianalyysi tehtiin kaikille 7 alkuperäiselle piirteelle ennen karsintaa. Käytössä olivat vain labeled setupit (n = 6 641 / 8 281). Naivi voitto-% labeled-joukolla oli 7,06 %.

4.1 Kvintiilitaulukko, alkuperäiset 7 piirrettä

Piirre	Q1	Q2	Q3	Q4	Q5	Q5-Q1
atr_15m_pct	11,1 %	8,6 %	6,2 %	5,0 %	4,4 %	-6,8 pp
atr_15m_vs_atr_daily	10,4 %	8,1 %	6,4 %	5,8 %	4,6 %	-5,8 pp
atr_1h_pct	11,6 %	7,2 %	6,9 %	5,1 %	4,5 %	-7,1 pp
atr_1h_vs_atr_daily	11,5 %	6,7 %	6,9 %	5,2 %	5,0 %	-6,5 pp
rsi_15m	5,3 %	7,8 %	11,3 %	5,9 %	5,0 %	-0,3 pp
rsi_1h	3,3 %	7,7 %	13,8 %	7,3 %	3,2 %	-0,1 pp
volume_vs_ma20_15m	6,4 %	6,6 %	7,7 %	7,4 %	7,3 %	+0,9 pp

4.2 Havainnot

ATR-piirteet osoittautuvat erittäin vahvoiksi ja monotonisiksi: voitto-% laskee suoraviivaisesti Q1:stä Q5:een kaikilla neljällä piirteellä. Q5–Q1-erotus on välillä –5,8 pp ja –7,1 pp. Vahvimmaksi piirteeksi osoittautuu atr_1h_pct.

RSI-piirteet näyttävät pinnallisesti heikoilta: Q5–Q1-erotus on käytännössä nolla molemmilla. Tarkempi tarkastelu paljastaa kuitenkin, että voitto-% noudattaa käänteistä U-kuviota – paras tulos on keskellä (Q3 = 13,8 % rsi_1h:lla). Tämä on poikkeuksellinen löytö, jota syvennetään luvussa 6.

Volyympipiirre on heikko: kvintilit ovat lähellä toisiaan (6,4–7,7 %) ja monotonisuus puuttuu. Suunta on lievästi vastoin alkuperäistä teorian odotusta (matalan volyymin oletettiin tuovan paremman voitto-%:n), mutta erotus on niin pieni, että tulos on käytännössä ei-merkittävä.

5. Korrelaatioanalyysi ja karsinta

Ennen mallinnusvaihetta tarkistettiin sekä Ryhmä D:n piirteiden keskinäiset korrelaatiot että ristikorrelaatiot aiempien ryhmien piirteisiin. Tämä on välttämätön askel, koska redundantti piirreavaruus heikentää mallien tulkittavuutta ja voi lisätä overfitting-riskiä.

5.1 Sisäiset korrelaatiot Ryhmä D:ssä

Vahvat sisäiset korrelaatiot ($|r| > 0,5$):

Piirre 1	Piirre 2	r
atr_15m_pct	atr_1h_pct	+0,89
rsi_15m	rsi_1h	+0,89
atr_15m_vs_atr_daily	atr_1h_vs_atr_daily	+0,86
atr_15m_pct	atr_15m_vs_atr_daily	+0,79
atr_1h_pct	atr_1h_vs_atr_daily	+0,71
atr_15m_pct	atr_1h_vs_atr_daily	+0,67
atr_15m_vs_atr_daily	atr_1h_pct	+0,60

5.2 Ristikorrelaatiot aiempiin ryhmiin

Vahvat korrelaatiot ($|r| > 0,5$) Ryhmä D:n ja aiempien ryhmien välillä:

Ryhmä D piirre	Aiempi piirre	r
rsi_1h	entry_position_in_box (A)	+0,91
rsi_15m	entry_position_in_box (A)	+0,89
atr_15m_pct	prev_day_range_pct (B)	+0,63
atr_1h_vs_atr_daily	box_size_vs_atr14d (B)	+0,59
atr_1h_pct	prev_day_range_pct (B)	+0,57
atr_15m_vs_atr_daily	prev_day_range_pct (B)	+0,51

5.3 Karsintapäätökset

Karsinnan kriteerinä on käytetty $|r| > 0,8$ sisäisessä korrelaatiossa. Karsittavaksi valitaan se piirre, joka on vähemmän informatiivinen tai jonka näkökulmaa toinen piirre kattaa paremmin. Karsittavat piirteet:

- atr_15m_pct (karsittu): $r = 0,89$ atr_1h_pct:n kanssa. Pidetään atr_1h_pct, koska sillä oli vahvin Q5–Q1-erotus (–7,1 pp).
- atr_1h_vs_atr_daily (karsittu): $r = 0,86$ atr_15m_vs_atr_daily:n kanssa. Pidetään atr_15m_vs_atr_daily, joka antaa pääaika-kehityksen näkökulman.
- rsi_15m (karsittu): $r = 0,89$ rsi_1h:n kanssa. Pidetään rsi_1h, koska 1h-aika-kehitys on stabiilimpi ja sen tulokset olivat hieman vahvempia.

Lopullinen piirreavaruus Ryhmä D:n osalta on siis 4 piirrettä:

- atr_15m_vs_atr_daily — suhteellinen volatilitiitti
- atr_1h_pct — absoluuttinen volatilitiitti
- rsi_1h — momentum
- volume_vs_ma20_15m — volyyimisuhde

5.4 Huomautus: rsi_1h vs. entry_position_in_box

Korrelaatiotarkastelu paljasti, että rsi_1h korreloi voimakkaasti ($r = 0,91$) Ryhmä A:n piirteeseen entry_position_in_box. Vaikka korrelaatio ylittää sisäisen karsintakynnyksen, piirre päätettiin säilyttää, koska:

- Piirteet mittaavat käsitteellisesti eri asioita: entry_position_in_box on hetken tilakuva (sisäänmenohinnan sijainti boxissa), kun taas rsi_1h on kertynyt momentum-historia tunnin aikajaksolla.
- Niiden eroavaisuuksissa voi olla informatiivista signaalia, jota ML-mallit voivat hyödyntää.
- Päätös dokumentoidaan tässä eksplisiittisesti, jotta lopullisessa raportissa korkea korrelaatio ei tule yllätyksenä.

6. Syventävä analyysi: RSI:n Simpson-paradoksi

Kvintiilianalyysin yhdistetty tulos rsi_1h:lle (Q5–Q1 = –0,1 pp, mutta käänteinen U-kuvio) herätti epäilyksen, että alaryhmittäin tarkasteltuna kuvio voisi olla eri. Jaettaessa setupit suunnan (direction) mukaan paljastui klassinen Simpsonin paradoksi -tyyppinen ilmiö: yhdistetty käänteinen U koostuu kahdesta vastakkaisesta monotonisesta trendistä.

6.1 Long-setupit (n = 3 296, voitto-% 7,46 %)

Kvintiili	RSI 1h alue	n	Voitto-%
Q1	[6,8 — 29,7]	661	1,4 %
Q2	[29,7 — 35,0]	658	5,3 %
Q3	[35,0 — 39,6]	659	5,2 %
Q4	[39,6 — 44,4]	659	9,7 %
Q5	[44,4 — 63,0]	659	15,8 %

Long-setupien voitto-% kasvaa monotonisesti RSI:n mukana: 1,4 % → 15,8 %. Tämä on päinvastainen suunta kuin klassinen mean reversion -teoria ennustaisi (oletettavasti matala RSI = ylimyyty = paras long-mahdollisuus).

6.2 Short-setupit (n = 3 345, voitto-% 6,67 %)

Kvintiili	RSI 1h alue	n	Voitto-%
Q1	[34,0 — 55,8]	669	12,3 %
Q2	[55,8 — 60,7]	669	9,1 %
Q3	[60,7 — 65,3]	669	5,5 %
Q4	[65,3 — 70,9]	669	3,4 %
Q5	[70,9 — 92,8]	669	3,0 %

Short-setupien voitto-% laskee monotonisesti RSI:n mukana: 12,3 % → 3,0 %. Tämä on jälleen päinvastainen suunta kuin klassinen mean reversion -teoria ennustaisi.

6.3 Tulkinta

Molemmissa alaryhmissä paras tulos saadaan, kun setup käy lyhyen aikavälin momenttia vastaan vähiten:

- Long-setupit menestyvät parhaiten, kun RSI on jo noussut neutraalin yli (44–63), eli markkinassa on lievä nouseva momentum.
- Short-setupit menestyvät parhaiten, kun RSI on neutraalin alapuolella (34–56), eli markkinassa on lievä laskeva momentum.
- Huonoimmat tulokset saadaan, kun setup käy radikaalisti vastoin momenttia (long alle 30, short yli 70).

Tulos on intuitiivisesti yhteensopiva Box Methodin sisäisen logiikan kanssa. Käännekynttilät havaitaan, kun hinta liikkuu pois boxista. Jos sisäänmenohetkellä RSI on jo ääripäässä, vahva momentum-liike on todennäköisesti jatkumassa eikä korjausliike (mean reversion) ole vielä alkamassa.

Pedagogisesti tämä on hyvä esimerkki Simpsonin paradoksista piirreanalyysissä: yhdistetty näkymä piirteestä voi peittää alaryhmittäin selkeät ja vahvat ilmiöt. Tämä on tärkeä metodologinen oppimispiste myös loppuraporttiin.

7. Keskeiset löydöt

Ryhmä D tuottaa seuraavat numeroidut löydökset (jatkoa aiempien ryhmien löytöjen numeroinnille):

#	Löytö	Vahvuus
9	atr_1h_pct monotoninen ja vahva: matala 11,6 % → korkea 4,5 %.	Erittäin vahva
10	atr_15m_vs_atr_daily monotoninen: matala 10,4 % → korkea 4,6 %.	Vahva
11	RSI:n Simpson-paradoksi: yhdistettynä käänteinen U, direction-jaolla vastakkaiset monotoniset trendit.	Erittäin vahva, vasta-intuitiivinen

#	Löytö	Vahvuus
12	Long-setup paras RSI 44–63: voitto-% 15,8 %; huonoin RSI < 30: 1,4 %.	Erittäin vahva
13	Short-setup paras RSI 34–56: voitto-% 12,3 %; huonoin RSI > 70: 3,0 %.	Erittäin vahva
14	volume_vs_ma20_15m: heikko, ei monotoninen (Q5–Q1 = +0,9 pp).	Heikko
15	rsi_1h korreloi voimakkaasti entry_position_in_box:n kanssa ($r = 0,91$). Piirteet pidetään silti molemmat eri käsitteellisten näkökulmien vuoksi.	Metodologisesti tärkeä

8. Yhteenveto teorian kannalta

Aiempien ryhmien tulosten pohjalta muotoiltu työhypoteesi oli:

"Box Method on mean reversion -strategia, joka toimii parhaiten rauhallisessa markkinassa."

Ryhmä D:n tulokset tukevat tätä työhypoteesia volatiliteetin osalta: ATR-piirteet vahvistavat selvästi sen, että matala volatiliteetti sisäänmenohetkellä korreloi paremman voitto-%:n kanssa. Tämä on jatkumoa Ryhmä B:n löydölle (box_size_vs_atr14d).

RSI:n direction-jakoanalyysi puolestaan rikastaa hypoteesia uudella ulottuvuudella. Päivitetty muotoilu:

"Box Method on mean reversion -strategia, joka toimii parhaiten rauhallisessa markkinassa, kun setup ei käy radikaalisti vastoin lyhyen aikavälin momenttia."

Tämä uusi muotoilu on yhteensopiva myös Ryhmä C:n yllättävän löydön kanssa (trend_aligned käänteinen): pitkän aikavälin rakenteellinen trendi (4h) ja lyhyen aikavälin momentum (1h) vaikuttavat eri tavoin. Box Method näyttää menestyvän, kun hinta liikkuu vastoin keskipitkän aikavälin rakennetta, mutta lievästi myötä lyhyen aikavälin momenttia — eli klassisen pullback-setupin tapaan.

Tämä rikastettu hypoteesi muodostaa Ryhmä D:n päätuotoksen ja tulee kantamaan tieteellistä painoarvoa loppuraportissa, riippumatta siitä, osoittautuvatko ML-mallit lopulta kannattaviksi vai eivät.

9. Vaiheen tuotokset

- Funktio add_group_d_features() src/features.py:ssä, sekä apufunktiot _calculate_atr() ja _calculate_rsi().
- Notebook-osio 03_features.ipynb:ssä, joka dokumentoi Ryhmä D:n laskennan, sanity-tarkistukset, kvintiilianalyysin ja korrelaatiotarkastelun.
- Päivitetty välitallennus data/processed/setups_with_features.parquet (8 281 riviä, 31 saraketta).
- Tämä löytödokumentti: docs/vaihe3_ryhma_d_loydot.docx.
- Git commit -historia kuvaa tehdyt muutokset ja päätökset.